ДИПЛОМНЫЙ ПРОЕКТ · «ИИ-РАЗРАБОТЧИК: ОТ API ДО АГЕНТОВ»

# AI-ассистент для анализа документов

Упрощает повседневные задачи аналитика компании: ответы по 66 документам с источниками, разбор файлов и агент, который действует только после подтверждения человека. Локально, на Ollama.

**Александра Бужор**
Итоговая аттестация · 2026

FastAPI · LlamaIndex · Qdrant · LangGraph
Ollama · Postgres · Redis · Telegram

ЗАДАЧА И ПОЛЬЗОВАТЕЛЬ

# Повседневные задачи аналитика компании

Аналитик разбирает обращения пользователей, ведёт бизнес-анализ и интеграции ERP и 1С. Ответы — в инструкциях, регламентах, документации API, а нужны они сразу, а не после ручного поиска.

## Сотрудник-аналитик

Спрашивает своими словами в Telegram, присылает PDF и DOCX на разбор, добавляет документы в базу. Ответ — сразу, со ссылкой на источник.

## Автор обращения

Пользователь сервиса или коллега. Агент готовит ему ответ, но отправляет только после подтверждения аналитика — действие необратимо.

**Сценарии:** Вопрос и уточнение в диалоге | Ответа нет в документах → честный отказ | Разбор PDF, DOCX, фото | Новый документ в базе | Агент: найти факт и ответить

ПОЧЕМУ ЗДЕСЬ НУЖЕН ИИ

# Почему не поиск по словам и не FAQ

## Вопрос — своими словами

«Потеряла телефон с аутентификатором» — а в статье «резервный код».

**Нужный фрагмент первым:** по словам — 6 из 10, bge-m3 — 9 из 10

## Ответ — в разных документах

«Не проходит оплата картой — что делать и как быстро ответит поддержка?»

Что проверить — статья о платежах (DOCX), срок — регламент (PDF). FAQ это не склеит.

## Диалог и действие

«А при оплате по счёту?» понятно только по истории — вопрос переписывается в полный.

«Ответь пользователю» — уже действие: это агент с инструментами.

**Цена ИИ — риск выдумки.** Поэтому ответ строится только по найденным фрагментам, со ссылками, а ниже порога близости модель не вызывается вовсе.

Мини-бенчмарк блока 5.1: 10 вопросов, MRR 0.717 по словам против 0.933 у bge-m3

БАЗА ЗНАНИЙ

# 66 документов в четырёх форматах

**66**
файлов

**11**
категорий

**102**
фрагмента

**916**
КБ всего

| Формат | Файлов | Что это |
|---|---|---|
| HTML | 26 | справка — страницы сайта |
| Markdown | 17 | API и частые вопросы |
| DOCX | 14 | финансы, внедрение |
| PDF | 9 | регламент, безопасность, выпуски |

## Почему эти документы

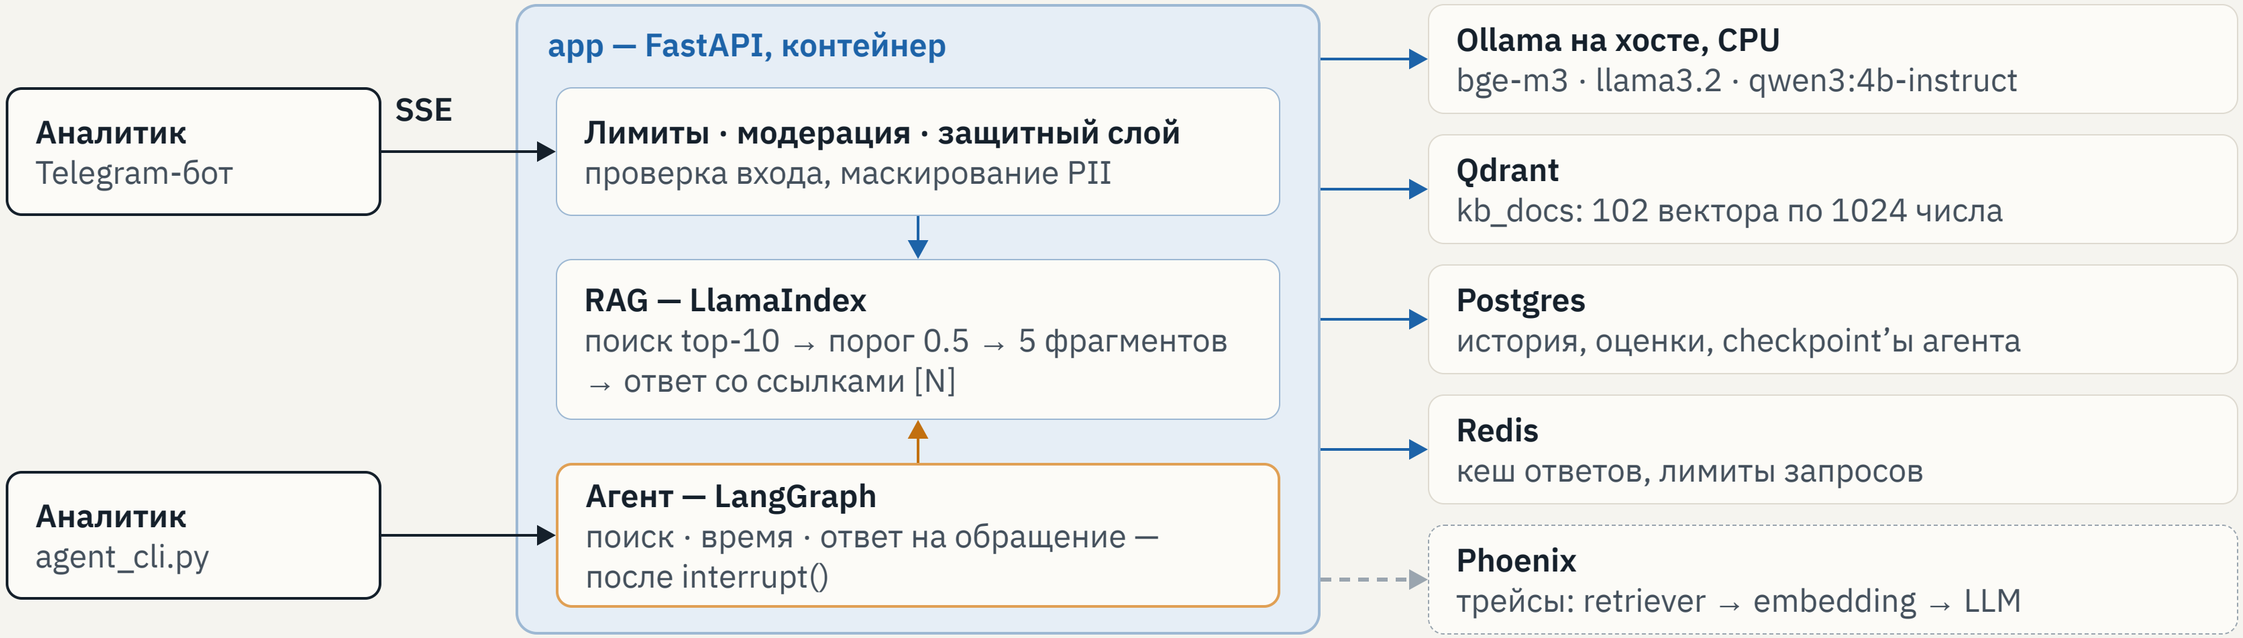
Документы работодателя публиковать нельзя — взята база проекта, она росла с модуля 3 и разложена по форматам, как в компании.

Ловушки, как в жизни: старые редакции не индексируются (возврат 7 → 14 дней), похожие статьи, таблицы в PDF.

Опись корпуса — docs/data_inventory.md; сборка — scripts/build_corpus.py

АРХИТЕКТУРА

# Один сервис, модели — локально в Ollama




**Поток SSE, а не запрос–ответ:** на CPU ответ идёт 20–40 с, пользователь видит, как он пишется.

**Бот — тонкий клиент:** модель, история, проверки — в сервисе; бот только показывает.

**Без шлюза LiteLLM:** проверен, но это лишний процесс там, где память занята Ollama.

Стек — compose.yaml, одна команда: docker compose up -d. Подробно — docs/decisions.md, раздел 4

ВЫБОР МОДЕЛИ

# Локальные модели в Ollama, на CPU ноутбука

| Роль | Модель | Почему она |
|---|---|---|
| Эмбеддинги | bge-m3, 1,2 ГБ | лучший поиск на русском: ruMTEB Retrieval 74.79 |
| Ответы по базе | llama3.2 3B, 2,0 ГБ | быстрее 4B на CPU, пороги RAGAS пройдены |
| Агент | qwen3:4b-instruct, 2,5 ГБ | одна из трёх прошла оба кейса tool calling |

## Почему не облако

gpt-4o-mini через OpenRouter быстрее и точнее, но оплата из РФ затруднена, у учебного ключа — 50 запросов в день, а документы и обращения ушли бы провайдеру.

## Машина и сервер

Сейчас — Ryzen 5 7530U, 16 ГБ, без GPU: ответ RAG за 27 с. Для живой поддержки — GPU 8–16 ГБ VRAM: RTX 5060 Ti 16 ГБ от ~55 тыс. ₽ или аренда от ~20 ₽/ч.

Цены — ориентир: 3DNews (2025), обзор GPU-хостингов Tproger (2026). Переход в облако — смена LLM__BASE_URL

ХРАНЕНИЕ И ПОИСК

# Qdrant и фрагменты по 512 токенов

| Решение | Выбрано | Альтернатива | Почему — по замерам |
|---|---|---|---|
| Векторная база | **Qdrant**, коллекция kb_docs | pgvector в том же Postgres | скорость та же; top-k полный при любом фильтре, гибридный поиск — в Query API |
| Нарезка | **recursive**, 512 / 64 токена | fixed, semantic; 256 токенов | строгий MRR@10: 0.964 против 0.958 и 0.946; при 256 токенах — 0.905 |
| Re-ranker | **выключен** | bge-reranker-v2-m3 | MRR тот же — 0.964; +69 % к задержке на CPU |
| Порог отказа | **0.5** по близости | 0.3 из задания курса | у bge-m3 своя шкала: зазор 0.448–0.593, 0 ошибок на 36 вопросах |

**Почему 512:** статьи справки короткие — медиана 135 токенов. Статья целиком в одном фрагменте, рядом с заголовком-вопросом. Модели — 5 лучших из 10 кандидатов.

Блок 5.4: 28 вопросов с эталонными фрагментами; калибровка порога — 28 вопросов по базе и 8 посторонних

АГЕНТНЫЙ СЛОЙ

# Один агент с паузой перед действием

**1. Модель решает,** что нужно: искать, узнать время или писать пользователю — qwen3:4b-instruct, не больше 6 вызовов

↓

**2. Инструменты:** search_knowledge_base — тот же RAG, что у бота; get_current_time — сроки от сегодняшнего дня

↓

**3. send_telegram_message** — меняет внешнее состояние: черновик и пауза interrupt()

↓

**4. Аналитик:** «Отправить ответ?» — y: отправка с ключом идемпотентности, n: отказ

**Пауза — в Postgres:** переживает docker compose restart, черновик тот же, сообщение не уйдёт дважды.

## Почему не мультиагент

**×2,42**
токенов на запрос

**×2,7**
вызовов модели

**+73 %**
время ответа, p50

**+0,2**
балла судьи из 5 — один вопрос

Supervisor + researcher + writer против одного агента на 5 вопросах. Задача — узкий поиск с общим контекстом и ответом сразу: здесь, по Anthropic, мультиагент проигрывает.

Блоки 6.3–6.5: docs/agent-persistent-report.md, docs/multi-agent-report.md

ПОВЕДЕНИЕ ПРИ СБОЯХ

# Понятный ответ вместо падения

| Что отказало | Что видит пользователь | Как устроено |
|---|---|---|
| API модели не отвечает | «Модель сейчас недоступна. Попробуйте через пару минут.» | повторы SDK → llm_unavailable, HTTP 502 с понятным JSON |
| Модель думает слишком долго | «Ответ занимает слишком долго…» | таймаут запроса → llm_timeout, 504 |
| Redis недоступен | ответы есть, но без кеша | кеш = промах; /ready — 503, /health — 200 |
| Qdrant или индекс | понятный текст о базе знаний | сервис стартует, RAG подключится позже |
| Перезапуск сервиса | диалог и пауза агента на месте | история и checkpoint’ы — в Postgres |

**Не встроено — резервный провайдер.** Цепочка «облако → Ollama → шаблон» с Circuit Breaker спроектирована (ADR-002) и проверена на LiteLLM: при неверном ключе OpenRouter ответила Ollama, клиент получил 200.

docs/decisions.md, раздел 8; docs/architecture.md — ADR-002 и прогон LiteLLM

РЕЗУЛЬТАТ

# Качество подтверждено числами

**0.868**
faithfulness — ответ опирается на фрагменты

**0.792**
answer relevancy — ответ по вопросу

**45 / 45**
ответов со ссылкой на источник

**44 / 45**
нужный фрагмент в первой пятёрке

**0.964**
строгий MRR@10 нарезки, 28 вопросов

**0**
ошибок порога отказа на 36 вопросах

**127 → 0**
успешных DAN-атак garak после защиты

**1596**
тестов — одной командой pytest

**Как проверялось:** golden dataset из 45 вопросов — генерация RAGAS и ручная вычитка 52 → 45; судья qwen3:4b-instruct; пороги 0.7 / 0.7 / 0.95 пройдены. Каждый ответ — дерево спанов в Phoenix.

docs/rag_evaluation.md, docs/chunking_experiment.md, docs/security/garak_after_2026-10-08.md

ОГРАНИЧЕНИЯ И ПЛАНЫ

# Где система ошибается и что дальше

## Где ошибается

- числа из соседнего фрагмента
- придуманные кнопки интерфейса
- ответ на половину двойного вопроса
- ссылки мимо эталона: 22 из 45 точны
- отказ на вопрос вне базы — так задумано

## Ограничения

- CPU: ответ 27 с, агент — 1–2 мин
- судья 4B шумит — рядом проверки кодом
- голос не проверен на API Whisper
- нет резервного провайдера
- отправка в Telegram — заглушка

## Планы

- облако → Ollama → шаблон, Circuit Breaker
- модель 7–8B на GPU и прогон RAGAS
- «Источники» — кодом, по результатам поиска
- правила: без выдуманных кнопок, каждая часть вопроса
- сильный судья для всех прогонов

Разбор провалов — docs/rag_evaluation.md, раздел 7; ограничения — docs/decisions.md, раздел 10

# Спасибо за внимание

Готова ответить на вопросы

Код и документация: github.com/AlexBuQA/multapi

Обоснование решений: docs/decisions.md

Демонстрация: видео 5–7 минут — ссылка в README